



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Grado en Master Universitario en Inteligencia Artificial

Trabajo Fin de Máster

TITULO Temporal

Autor: Jordi Florit Ensenyat
Tutor: Javier Melero

Madrid, MES - AÑO

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado

Grado en Master Universitario en Inteligencia Artificial

Título: TITULO Temporal

MES - AÑO

Autor: Jordi Florit Ensenyat

Tutor: Javier Melero

DEPARTAMENTO

Escuela Técnica Superior de Ingenieros Informáticos

Universidad Politécnica de Madrid

Índice general

1. Introducción	3
1.1. Motivación del proyecto	3
1.2. Contexto del proyecto	4
1.3. Objetivos	5
1.4. Estructura del Documento	5
2. Trabajo relacionado y Estado del Arte	7
2.1. Marcos software para robótica aérea	7
2.2. Aprendizaje por refuerzo para el control de UAV	8
2.3. Simuladores y entornos de entrenamiento para RL en drones	9
2.4. Síntesis crítica y posicionamiento del trabajo	10
3. Desarrollo	11
3.1. Apartado 1 de capítulo 2	11
3.1.1. Sección 1 de apartado 1 de capítulo 2	11
3.1.1.1. Sub sección 1	11
3.1.1.2. Sub sección 2	11
3.1.2. Sección 2 de apartado 1 de capítulo 2	11
3.2. Apartado 2 de capítulo 2	11
3.3. Apartado 3 de capítulo 2	11
4. Impacto del trabajo	12
4.1. Impacto general	12
4.2. Objetivos de Desarrollo Sostenible	12
5. Resultados y conclusiones	13
5.1. Resultados	13
5.2. Conclusiones personales	13
5.3. Trabajo futuro	13
Bibliografía	14
A. Anexo	16

Índice de Figuras

Índice de Tablas

Índice de Listings

Resumen

«Aquí va el resumen del TFG. Extensión máxima 2 páginas.»

Palabras Clave:

Abstract

«Abstract of the Final Degree Project. Maximum length: 2 pages.»

Keywords:

Capítulo 1

Introducción

Este capítulo presenta el marco general del Trabajo Fin de Máster, centrado en la aplicación de aprendizaje por refuerzo al control de vehículos aéreos no tripulados dentro del ecosistema Aerostack2. En primer lugar se expone la motivación del proyecto y su relevancia en el contexto actual de la robótica aérea autónoma. A continuación se describe el contexto técnico y de investigación en el que se enmarca el trabajo, así como el estado actual del desarrollo realizado hasta la fecha. Posteriormente se detallan el objetivo general y los objetivos específicos que guían la tesis. Por último, se resume la estructura del documento.

1.1. Motivación del proyecto

Los vehículos aéreos no tripulados han pasado en pocos años de ser una tecnología principalmente experimental a convertirse en una herramienta útil en aplicaciones industriales, logísticas, de inspección y competición. En todos estos escenarios, la autonomía y la capacidad de respuesta del vehículo son aspectos críticos, especialmente cuando el dron debe seguir trayectorias dinámicas, reaccionar ante referencias cambiantes o mantener un comportamiento estable a altas velocidades.

Dentro de este contexto, el control clásico basado en reguladores PID sigue siendo una solución ampliamente utilizada por su simplicidad, interpretabilidad y robustez. Sin embargo, cuando la dinámica del sistema es fuertemente no lineal y el régimen de operación es exigente, el ajuste manual de estos controladores puede resultar costoso y su capacidad de generalización limitada. Frente a ello, el aprendizaje por refuerzo ofrece una alternativa atractiva: permitir que una política de control aprenda a actuar a partir de la interacción con un entorno, optimizando directamente un criterio de comportamiento definido mediante recompensas.

La motivación de este trabajo surge precisamente en la intersección entre robótica aérea e inteligencia artificial. En el grupo CVAR (*Computer Vision and Aerial Robotics*) existe interés en desarrollar soluciones de control cada vez más ágiles para drones, en particular en el marco de la competición A2RL, donde el rendimiento del vehículo depende de su capacidad para ejecutar maniobras rápidas y precisas. Para que este tipo de aproximación sea viable, resulta imprescindible disponer de un entorno de entrenamiento que sea fiel desde el punto de vista dinámico, pero también lo suficientemente ligero como para permitir entrenar múltiples agentes en paralelo.

Este Trabajo Fin de Máster responde a esa necesidad. La idea central no es solamente entrenar un controlador con aprendizaje por refuerzo, sino construir una infraestructura experimental que conecte de forma correcta el simulador dinámico de Aerostack2 con una interfaz estándar de aprendizaje, de manera que el entrenamiento, la evaluación y la comparación con soluciones convencionales puedan realizarse de forma sistemática y reproducible.

1.2. Contexto del proyecto

El trabajo se desarrolla sobre Aerostack2, un *framework* para robótica aérea basado en ROS 2 que proporciona componentes reutilizables para control, estimación, comportamientos de vuelo e integración con diferentes plataformas y simuladores. En particular, este proyecto utiliza el simulador dinámico de multirrotores de Aerostack2, una herramienta sin interfaz gráfica que modela la dinámica del vehículo y que puede visualizarse mediante RViz2. La elección de este simulador es especialmente relevante para aprendizaje por refuerzo, ya que su bajo coste computacional permite plantear entornos vectorizados y ejecutar muchas instancias en paralelo, aumentando la eficiencia del muestreo durante el entrenamiento.

La propuesta inicial del tutor establece una progresión clara. En una primera fase es necesario comprender el funcionamiento de Aerostack2, del simulador de multirrotores y de las interfaces ROS 2 disponibles. Sobre esa base debe construirse un entorno de aprendizaje por refuerzo cuya entrada y salida estén definidas de forma coherente con el problema de control planteado. Más adelante, una vez validada la comunicación y la consistencia temporal de los datos, se abordarán aspectos propiamente relacionados con el aprendizaje, como el diseño de recompensas, la elección del algoritmo, el ajuste de hiperparámetros o la comparación frente a un controlador PID convencional.

El estado actual del proyecto refleja precisamente esa primera fase de integración. En el repositorio `rl_uav_aerostack2` se ha implementado un entorno mínimo en Gymnasium, denominado `AS2TestEnv`, cuya finalidad es verificar la conectividad entre el simulador y el entorno de aprendizaje. Este entorno encapsula el ciclo básico `reset-step-close`, inicializa la interfaz `DroneInterface` de Aerostack2, arma el dron, activa el modo *offboard*, ejecuta el despegue, envía comandos de velocidad lineal y lee observaciones compuestas por posición y velocidad. Junto a ello, el repositorio incluye scripts de lanzamiento del simulador, configuración del mundo, un controlador PID de referencia y un script de prueba que permite comprobar el intercambio de observaciones y acciones.

Por tanto, el trabajo realizado hasta el momento no corresponde todavía al entrenamiento final del controlador, sino a una etapa fundacional imprescindible: garantizar que la interfaz entre simulación, middleware robótico y entorno de aprendizaje funciona de manera estable. Esta validación es especialmente importante en un problema como el presente, donde la calidad del entrenamiento depende de que el agente reciba observaciones correctas, aplique acciones en el instante adecuado y pueda escalar posteriormente a ejecuciones paralelas.

1.3. Objetivos

El objetivo general de este Trabajo Fin de Máster es desarrollar un entorno de aprendizaje por refuerzo sobre el simulador dinámico de multirrotores de Aerostack2 y utilizarlo para entrenar y evaluar un controlador de alto nivel para un dron, capaz de recibir como entrada una referencia de posición global $[x, y, z]$ y generar como salida comandos de velocidad $[v_x, v_y, v_z, \omega_z]$, manteniendo además una orientación en yaw alineada con el vector velocidad.

Para alcanzar este objetivo general, el trabajo se divide en los siguientes objetivos específicos:

- Familiarizarse con el ecosistema Aerostack2, su organización en ROS 2 y el funcionamiento del simulador dinámico de multirrotores, identificando los componentes necesarios para el control del vehículo y el intercambio de información con el exterior.
- Diseñar e implementar una primera interfaz entre el simulador y un entorno compatible con Gymnasium, de forma que el problema pueda abordarse posteriormente con herramientas estándar de aprendizaje por refuerzo.
- Validar experimentalmente el ciclo básico de interacción del entorno, incluyendo inicialización, despegue, envío de acciones, recepción de observaciones y finalización segura de la simulación.
- Extender esta base hacia un entorno vectorizado que permita ejecutar múltiples simulaciones en paralelo, aprovechando el bajo coste computacional del simulador para mejorar la eficiencia del entrenamiento.
- Definir un problema de control progresivo en el que el agente aprenda a transformar referencias de posición en comandos de velocidad, incorporando explícitamente el requisito de *path facing*, es decir, que el yaw del dron quede alineado con la dirección de movimiento.
- Entrenar y evaluar un controlador basado en aprendizaje por refuerzo en diferentes escenarios de simulación con referencias secuenciales, y comparar su comportamiento frente a un controlador PID convencional utilizado como línea base.
- Como posible extensión, estudiar una arquitectura jerárquica o en cascada en la que un segundo controlador aprenda a transformar velocidades deseadas en consignas de tasas angulares, aproximando así el problema a un control de menor nivel.

1.4. Estructura del Documento

El documento se organiza en varios capítulos que recogen tanto el contexto del problema como el desarrollo técnico del trabajo. Tras este capítulo introductorio, el Capítulo 2 presenta el estado del arte y el contexto tecnológico relacionado con el aprendizaje por refuerzo, el control de drones y las herramientas empleadas. El Capítulo 3 describe el desarrollo realizado, prestando especial atención a la integración entre Aerostack2, el simulador de multirrotores y el entorno de aprendizaje implementado.

Posteriormente, el Capítulo 4 aborda el impacto del proyecto desde distintas perspectivas relevantes para un trabajo de ingeniería. El Capítulo 5 recoge los resultados obtenidos y la discusión asociada, incluyendo la validación del entorno y, en fases posteriores del trabajo, la evaluación de los controladores desarrollados. Finalmente, el documento se cierra con la bibliografía y los anexos, donde se podrá incluir material complementario de carácter técnico.

Capítulo 2

Trabajo relacionado y Estado del Arte

Este capítulo revisa el estado del arte relacionado con el control de vehículos aéreos no tripulados mediante aprendizaje por refuerzo y con las infraestructuras software y de simulación necesarias para su desarrollo. La revisión se organiza en torno a cuatro ejes. En primer lugar, se presentan algunos marcos software relevantes en robótica aérea y, en particular, la evolución desde Aerostack hasta Aerostack2. A continuación, se analizan las principales líneas de trabajo en control de cuadricópteros mediante aprendizaje por refuerzo, diferenciando entre control a bajo nivel, seguimiento de trayectorias y vuelo agresivo. En tercer lugar, se estudian los simuladores y entornos de entrenamiento más utilizados en la literatura. Finalmente, se sintetizan las limitaciones observadas y se posiciona el presente trabajo respecto a ellas.

2.1. Marcos software para robótica aérea

El desarrollo de sistemas aéreos autónomos requiere combinar de forma coherente control, estimación, percepción, planificación y coordinación entre múltiples componentes heterogéneos. Este problema de integración ha sido identificado desde hace años como uno de los principales obstáculos para trasladar algoritmos aislados a sistemas robóticos completos [1]. En ese contexto, Sánchez-López et al. propusieron Aerostack como un marco software abierto, modular y multicapa orientado al desarrollo de sistemas aéreos autónomos complejos [1]. Su aportación más relevante fue proporcionar una arquitectura reutilizable, específicamente diseñada para robótica aérea, capaz de integrar desde funciones reactivas de control hasta capas deliberativas y sociales para misiones de mayor complejidad.

La evolución natural de esta línea es Aerostack2, rediseñado sobre ROS 2 y orientado a sistemas aéreos multi-robot más versátiles y portables [2]. Frente a la versión anterior, Aerostack2 enfatiza la independencia de plataforma, la arquitectura basada en *plugins* y la definición de misiones a través de comportamientos, lo que facilita reutilizar componentes y conectar diferentes simuladores o plataformas reales. Para este TFM, Aerostack2 no es solo una herramienta de soporte, sino el sustrato tecnológico sobre el que se construye el entorno experimental. Por ello, resulta especialmente relevante en la revisión del estado del arte, ya que buena parte de los trabajos pu-

blicados en aprendizaje por refuerzo para drones se apoyan en simuladores o *stacks* propios, pero no en ecosistemas modulares integrados con ROS 2 de uso directo en robótica aérea.

2.2. Aprendizaje por refuerzo para el control de UAV

Las revisiones recientes muestran que el aprendizaje por refuerzo profundo se ha aplicado a problemas de planificación, navegación y control de UAV, con especial interés en escenarios donde la dinámica del vehículo es no lineal o donde el diseño manual del controlador resulta costoso [3]. Al mismo tiempo, la literatura también subraya limitaciones persistentes: tiempos de entrenamiento elevados, dificultades de transferencia del simulador al mundo real y fuerte dependencia de la calidad del entorno de simulación [3, 4].

Una parte significativa de los trabajos se ha centrado en control a bajo nivel, es decir, en aprender políticas que actúan cerca de los actuadores o de las consignas de actitud. Pi et al. propusieron un controlador de bajo nivel basado en aprendizaje por refuerzo capaz de generalizar a vehículos multirrotor con distintas configuraciones físicas, tratando de reducir la necesidad de reentrenamiento cuando cambian los parámetros del vehículo [5]. En una línea relacionada, Yoo et al. combinaron controladores deterministas clásicos con una política aprendida, mostrando que una aproximación híbrida puede mejorar la convergencia y el seguimiento de trayectorias mediante control en velocidad [6]. Estos trabajos son especialmente relevantes para la extensión futura planteada en esta tesis, en la que se contempla encadenar un controlador de alto nivel con otro de menor nivel que produzca tasas angulares.

Otra línea muy activa es la del vuelo agresivo y el empuje del dron hacia sus límites dinámicos. Kaufmann et al. demostraron en *Deep Drone Acrobatics* que es posible entrenar en simulación una política para realizar maniobras acrobáticas y transferirla al dron real sin ajuste fino posterior [7]. Más adelante, los mismos autores analizaron comparativamente distintas abstracciones de control y observaron que las políticas que actúan sobre *body-rates* y thrust resultan más robustas en transferencia que aquellas que operan directamente sobre los motores [8]. Este punto es de gran interés para el presente trabajo, porque ayuda a entender que el nivel de abstracción elegido para la acción no es una decisión menor, sino un elemento central del diseño del problema de aprendizaje.

Los resultados más recientes en vuelo agresivo refuerzan esta idea. Eschmann et al. mostraron que, con una arquitectura adecuada y un simulador muy optimizado, es posible entrenar controladores de bajo nivel en tiempos extraordinariamente reducidos y mantener capacidad de transferencia a plataformas reales [9]. En paralelo, Song et al. estudiaron de manera sistemática la competición entre control óptimo y aprendizaje por refuerzo en un problema de carrera autónoma con drones, concluyendo que RL puede superar al control óptimo cuando el objetivo se formula directamente a nivel de tarea y se entrena con suficiente robustez frente a incertidumbres del modelo [10]. Este resultado es particularmente pertinente dado el contexto de A2RL que motiva la tesis.

Sin embargo, la literatura revisada también revela una cierta dispersión en el tipo de problema abordado. Muchos trabajos se centran en estabilización de actitud, control a nivel de actuadores, vuelo acrobático o navegación end-to-end basada en percep-

ción [7, 5, 6]. Por el contrario, es menos frecuente encontrar trabajos orientados a un controlador intermedio de alto nivel, cuya entrada sea una referencia de posición global y cuya salida sean velocidades lineales y velocidad angular en yaw, integrados además en un *stack* robótico como Aerostack2. Esta observación es una inferencia a partir de las obras revisadas y ayuda a justificar el espacio de contribución de este TFM.

2.3. Simuladores y entornos de entrenamiento para RL en drones

El entrenamiento mediante aprendizaje por refuerzo en robótica aérea depende fuertemente del simulador empleado. Un simulador adecuado debe ofrecer fidelidad dinámica suficiente para capturar el comportamiento del vehículo, pero también un coste computacional reducido que permita generar gran cantidad de experiencia de entrenamiento [4]. La literatura reciente coincide en que este equilibrio entre realismo, velocidad y facilidad de integración es uno de los factores determinantes del éxito de una solución basada en RL [3, 4].

Entre los entornos más influyentes se encuentra Flightmare, un simulador de cuadricópteros diseñado para desacoplar el renderizado y la física, lo que permite combinar flexibilidad con una velocidad de simulación muy elevada [11]. Su interés para aprendizaje por refuerzo reside en que puede simular centenares de drones en paralelo, lo cual lo convierte en una referencia cuando el objetivo es maximizar el rendimiento de muestreo. Desde otra perspectiva, Air Learning amplió el uso de AirSim con un entorno tipo Gym para navegación autónoma, introduciendo aleatorización del dominio, *hardware-in-the-loop* y métricas de “calidad de vuelo” orientadas al despliegue en plataformas con recursos limitados [12]. Este trabajo es relevante porque muestra que el valor de un simulador para RL no depende solo de la dinámica, sino también de su capacidad para aproximar las restricciones computacionales del sistema final.

En una dirección más ligera y abierta, Panerati et al. propusieron un entorno Gym basado en PyBullet para cuadricópteros individuales y multiagente, explícitamente orientado a facilitar la comparación entre enfoques de control clásico y de aprendizaje [13]. Su aportación es especialmente interesante para trabajos académicos porque reduce la fricción de entrada, ofrece portabilidad y proporciona ejemplos tanto de control PID como de tareas de RL. Finalmente, *Learning to Fly in Seconds* plantea un simulador extremadamente optimizado para entrenamiento de controladores de bajo nivel, subrayando que la eficiencia computacional puede llegar a ser tan importante como la fidelidad dinámica cuando el objetivo es acelerar el ciclo de investigación [9].

Las revisiones de conjunto confirman esta diversidad de soluciones. Chan et al. comparan simuladores orientados a RL desde la perspectiva de sus prestaciones, interfaces y capacidades de integración, y concluyen que no existe una herramienta universalmente superior, sino distintas elecciones dependiendo del problema, del tipo de aprendizaje y del nivel de realismo requerido [4]. Desde la perspectiva de este TFM, esta conclusión es importante: el simulador de multirrotores de Aerostack2 puede no ofrecer el fotorrealismo de otras plataformas, pero su ligereza y su integración natural con ROS 2 lo hacen especialmente atractivo para un entorno vectorizado de entrenamiento orientado al control dinámico.

2.4. Síntesis crítica y posicionamiento del trabajo

La revisión anterior permite extraer varias conclusiones. En primer lugar, el aprendizaje por refuerzo ha demostrado ser una herramienta válida para el control de drones en problemas de estabilización, seguimiento, navegación y vuelo agresivo [7, 5, 6, 10]. En segundo lugar, el rendimiento final depende de forma decisiva del nivel de abstracción de la acción, del diseño de la recompensa y de la calidad del simulador empleado [8, 4]. En tercer lugar, la literatura ha prestado especial atención a simuladores propios o entornos Gym independientes, pero menos a la integración del aprendizaje por refuerzo con *frameworks* modulares de robótica aérea basados en ROS 2 [2, 11, 12, 13].

A partir de las fuentes revisadas, puede inferirse que existe una oportunidad de investigación en la construcción de entornos de aprendizaje por refuerzo ligeros, vectorizables y directamente integrados con un *stack* robótico operativo como Aerostack2. Esta necesidad es todavía más clara cuando el problema de control no se formula a nivel de actuadores, sino a un nivel intermedio más próximo a la planificación y a la ejecución de misiones: recibir una referencia global de posición y generar comandos de velocidad compatibles con la arquitectura del dron, imponiendo además una restricción funcional sobre la orientación en yaw para alinear el dron con su dirección de movimiento.

En este punto se sitúa el presente Trabajo Fin de Máster. La contribución propuesta no consiste solo en entrenar un controlador, sino en sentar la base experimental necesaria para hacerlo dentro de Aerostack2: validar la interfaz entre simulador, ROS 2 y entorno de aprendizaje, preparar un entorno vectorizable y establecer posteriormente una comparación rigurosa frente a un controlador PID de referencia. Desde esta perspectiva, el trabajo se alinea con la literatura más reciente sobre control aprendido para cuadricópteros, pero aporta un enfoque diferencial en términos de integración software, reproducibilidad y adecuación a un problema de control jerárquico progresivo.

Capítulo 3

Desarrollo

«Capítulo dedicado a describir el desarrollo del Trabajo realizado. De acuerdo con el tutor, este capítulo puede tener distintas estructuras, e incluso pueden existir varios capítulos.»

«Todos los capítulos deben empezar en una página nueva.»

«Los apartados dentro de los capítulos se numeran de forma jerárquica, pero siempre deben estar alineados al margen izquierdo»

3.1. Apartado 1 de capítulo 2

3.1.1. Sección 1 de apartado 1 de capítulo 2

3.1.1.1. Sub sección 1

3.1.1.2. Sub sección 2

3.1.2. Sección 2 de apartado 1 de capítulo 2

3.2. Apartado 2 de capítulo 2

3.3. Apartado 3 de capítulo 2

Capítulo 4

Impacto del trabajo

«Breve explicación, por secciones, de los contenidos de este capítulo»

4.1. Impacto general

«Análisis del impacto potencial de los resultados obtenidos durante la realización del TFG, en los diferentes contextos para los que se aplique. Además, se harán notar aquellas decisiones tomadas a lo largo del trabajo que tienen como base la consideración del impacto.»

4.2. Objetivos de Desarrollo Sostenible

«Se recomienda analizar también el potencial impacto respecto a los Objetivos de Desarrollo Sostenible (ODS), de la Agenda 2030, que sean relevantes para el trabajo realizado (ver enlace 1, ver enlace 2)»

Capítulo 5

Resultados y conclusiones

«Breve explicación, por secciones, de los contenidos de este capítulo»

5.1. Resultados

«Resumen de resultados obtenidos en el TFG»

5.2. Conclusiones personales

«Conclusiones personales del estudiante sobre el trabajo realizado»

5.3. Trabajo futuro

«Trabajo futuro que no se haya podido realizar o siguientes pasos que tomará el desarrollo realizado en este TFG»

Bibliografía

- [1] José Luis Sánchez-López et al. «A Multi-Layered Component-Based Approach for the Development of Aerial Robotic Systems: The Aerostack Framework». En: *Journal of Intelligent & Robotic Systems* 88.2–4 (2017), págs. 683-709. DOI: 10.1007/s10846-017-0551-4. URL: <https://doi.org/10.1007/s10846-017-0551-4>.
- [2] Miguel Fernández-Cortizas et al. «Aerostack2: A Software Framework for Developing Multi-robot Aerial Systems». En: *arXiv preprint arXiv:2303.18237* (2023). DOI: 10.48550/arXiv.2303.18237. URL: <https://arxiv.org/abs/2303.18237>.
- [3] Ahmad Taher Azar et al. «Drone Deep Reinforcement Learning: A Review». En: *Electronics* 10.9 (2021), pág. 999. DOI: 10.3390/electronics10090999. URL: <https://doi.org/10.3390/electronics10090999>.
- [4] Jun Hoong Chan et al. «Reinforcement Learning-based Drone Simulators: Survey, Practice, and Challenge». En: *Artificial Intelligence Review* 57.10 (2024), pág. 281. DOI: 10.1007/s10462-024-10933-w. URL: <https://doi.org/10.1007/s10462-024-10933-w>.
- [5] Chen-Huan Pi et al. «General Purpose Low-Level Reinforcement Learning Control for Multi-Axis Rotor Aerial Vehicles». En: *Sensors* 21.13 (2021), pág. 4560. DOI: 10.3390/s21134560. URL: <https://doi.org/10.3390/s21134560>.
- [6] Jaehyun Yoo et al. «Hybrid Reinforcement Learning Control for a Micro Quadrotor Flight». En: *IEEE Control Systems Letters* 5.2 (2021), págs. 505-510. DOI: 10.1109/LCSYS.2020.3001663. URL: <https://doi.org/10.1109/LCSYS.2020.3001663>.
- [7] Elia Kaufmann et al. «Deep Drone Acrobatics». En: *Proceedings of Robotics: Science and Systems*. Corvallis, Oregon, USA, 2020. DOI: 10.15607/RSS.2020.XVI.040. URL: <https://www.roboticsproceedings.org/rss16/p040.html>.
- [8] Elia Kaufmann, Leonard Bauersfeld y Davide Scaramuzza. «A Benchmark Comparison of Learned Control Policies for Agile Quadrotor Flight». En: *2022 International Conference on Robotics and Automation (ICRA)*. 2022, págs. 10504-10510. DOI: 10.1109/ICRA46639.2022.9811564. URL: <https://doi.org/10.1109/ICRA46639.2022.9811564>.
- [9] Jonas Eschmann, Dario Albani y Giuseppe Loianno. «Learning to Fly in Seconds». En: *IEEE Robotics and Automation Letters* 9.7 (2024), págs. 6336-6343. DOI: 10.1109/LRA.2024.3396025. URL: <https://doi.org/10.1109/LRA.2024.3396025>.
- [10] Yunlong Song et al. «Reaching the Limit in Autonomous Racing: Optimal Control versus Reinforcement Learning». En: *Science Robotics* 8.82 (2023), eadg1462.

- DOI: 10.1126/scirobotics.adg1462. URL: <https://doi.org/10.1126/scirobotics.adg1462>.
- [11] Yunlong Song et al. «Flightmare: A Flexible Quadrotor Simulator». En: *Proceedings of the 5th Conference on Robot Learning*. Vol. 155. Proceedings of Machine Learning Research. PMLR, 2021, págs. 1147-1157. URL: <https://proceedings.mlr.press/v155/song21a.html>.
- [12] Srivatsan Krishnan et al. «Air Learning: a Deep Reinforcement Learning Gym for Autonomous Aerial Robot Visual Navigation». En: *Machine Learning* 110 (2021), págs. 2501-2540. DOI: 10.1007/s10994-021-06006-6. URL: <https://doi.org/10.1007/s10994-021-06006-6>.
- [13] Jacopo Panerati et al. «Learning to Fly — a Gym Environment with PyBullet Physics for Reinforcement Learning of Multi-agent Quadcopter Control». En: *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. 2021, págs. 7512-7519. DOI: 10.1109/IROS51168.2021.9635857. URL: <https://doi.org/10.1109/IROS51168.2021.9635857>.

Apéndice A

Anexo

«Este capítulo (anexo) es opcional, y se escribirá de acuerdo con las indicaciones del Tutor.»